

AiScientist：面向单细胞与眼科基因组学的隐私优先多智能体研究 控制台

系统实现、能力评估与模型托管需求

UCI RUIC20 实验室 · 版本 0.2.0 “DAG” · 2026-09-05

目录

1	摘要	1
2	引言	3
2.1	问题	3
2.2	方案	3
2.3	命名	3
3	方法	4
3.1	系统体系结构	4
3.2	智能体研究实验室	5
3.3	分析工具的实现	5
3.4	模型评测设计	6
3.5	自托管容量与 GPU 台数估算方法	6
3.6	机制验证的设计	7
4	结果	8
4.1	已部署的能力	8
4.2	覆盖的研究场景	8
4.3	分析产出示例	9
4.4	模型评测结果	13
4.5	GPU 托管需求	15
4.6	机制验证结果	16
5	讨论	18
	补充材料	19
S1	操作指南	19
S2	工具目录	21
S3	技术栈	23
S4	术语表	24
S5	关键环境变量	24
S6	路径约定	25
S7	仓库结构	25
S8	补充图例	26
S9	资料出处	28

1 摘要

单细胞与空间转录组分析是一条由判断构成的长链：质控阈值、聚类分辨率、差异表达检验的选择、富集库的选择、marker 的解读、结论与文献的对齐。这条链目前由领域科学家横跨多个工具手工完成，参数选择通常不留记

录。

我们构建了 **AiScientist**: 一个隐私优先的多智能体生物信息学研究控制台, 部署于 UCI 校园网 (aiscientist.eye.som.uci.edu)。研究者在浏览器中用自然语言提出科学问题并指定数据集, 系统通过 SSH 连接 UCI HPC3, 在 Slurm GPU 上以 vLLM 托管开源权重模型, 驱动一个 PI → Scientist → Critic 的角色化循环调用真实分析工具, 最终输出带图、带表、可引用的 PDF/DOCX 手稿与可下载结果包。原始数据不离开校园网, 全部重算力以 Singularity 容器化的 Slurm 作业形式运行于集群。

系统当前包含 39,916 行 Python (8 个子包)、1,611 条离线测试、30 余个具名工具、15 个可重写原子技能与 7 条预设流水线, 覆盖条件对比差异表达、细胞类型注释、变异解读、表型驱动鉴别诊断等九类研究场景。本文以一次真实运行 (15,307 细胞 × 33,696 基因, 产出 12 页手稿、26 张图、80 余张表) 说明产出形态。

我们另建立了一套模型可替换性评测框架, 在不改动脚手架、只替换模型的前提下比较十种模型配置在规划、执行、写作三个阶段的表现, 并据此给出角色分流的选型建议与自托管所需的 GPU 台数估算 (覆盖 RTX PRO 4500/5000/6000 Blackwell、B200、B300 五类在售设备)。四项关键机制在已知答案或真实服务模型上做了独立验证。

2 引言

2.1 问题

单细胞与空间分析的每一步都包含可辩护但不唯一的选择。质控阈值取 5% 还是 10% 取决于样本是细胞还是细胞核；聚类分辨率决定了下游每一个细胞类型标签；条件对比究竟应当在细胞层面做还是聚合到样本层面，取决于生物学重复的数目；测序深度在两臂之间的失衡会把技术效应伪装成生物学。这些判断分散在不同工具与不同人的习惯里，且很少被完整记录。

2.2 方案

AiScientist 把这条链实现为一支受监督的智能体团队，并遵循三条设计原则。

隐私优先。模型运行在 UCI HPC3 的 GPU 上，权重与推理不出校园网。原始数据集只存在于服务端与 HPC3，网关不保留副本。DataBoundaryGuard 在任何模型调用之前审查提示词，拦截原始数据行与密钥。对外的文献检索经过消毒，只携带一个裸文件名与研究问题本身；深度文献检索使用会话内的本地模型端点与本地 embedding 模型，语料分块不出校园。

重算力留在集群。GPU 推理、代码沙箱、scanpy 分析、报告渲染、scGPT 注释与视觉复核，全部作为 Singularity 容器化的 Slurm 作业在 HPC3 上运行。文件传输走专用传输节点，与 RCIC 对登录节点的使用规范一致。

结果可核验。工具如实返回状态，缺依赖时返回 `dependency_missing` 而非伪装完成。一道确定性守卫（代码而非提示词）约束评审角色的接受条件。报告组装完全不经模型，图表按工具产出的文件原样嵌入。

2.3 命名


产品名为 **AiScientist**（前身 BioAgent），所有面向用户的文字统一使用该名。代码命名空间保留 `bioagent`：Python 包 `src/bioagent/`、环境变量 `BIOAGENT_*`、生产数据目录 `/data/BioAgent`、systemd 服务与 SSH 服务账号 `bioagent`。`core.config.apply_brand_env_aliases()` 在加载 `.env` 时双向镜像 `BIOAGENT_*` 与 `AISCIENTIST_*`，两种前缀均可解析。

3 方法

3.1 系统体系结构

系统分两层，靠 per-session 的 SSH 隧道与 Slurm 作业提交解耦。web 层不持有 GPU，也不持有数据集的常驻副本。

浏览器 --HTTPS--> Envoy Gateway (aiscientist.eye.som.uci.edu)



代码组织如下。

子包	职责	文件数	行数
agents/	研究实验室 (PI/Scientist/Critic)、DAG 规划器、专家记忆、工具注册表、代码沙箱、溯源	20	10,701
gateway/	web 控制台: SSH+Duo、Slurm vLLM 拉起与隧道、账号、聊天历史、上传、报告组装、HPC3 offload	33	15,383
tools/	真实分析 (scanpy/gseapy)、文献 (Europe PMC + PaperQA2)、报告 (pandoc)、scGPT、视觉复核、示意图、变异、表型	30	11,990
integrations/	DataBoundaryGuard 安全层	5	761
lab/	研究实验室支撑	3	468
providers/	OpenAI 兼容 LLM 客户端 (含回落)	2	266
hpc/	Slurm 边界	2	226
core/	共享配置、品牌环境变量别名	2	113
合计		97	39,916

前端为 5,244 行原生 JavaScript (无框架, 按请求从磁盘提供), 含 Cytoscape 用于 DAG 视图、Mermaid 用于内联图。
数据边界。一次运行中数据经过三道边界:

阶段	数据位置	边界
上传	浏览器 → 网关 (分块) → HPC3 用户目录	网关不保留副本
分析	HPC3 计算节点, 容器内读写	原始矩阵从不进入提示词
模型调用	提示词经 DataBoundaryGuard 审查后送入本地 vLLM	第一道: 拦截原始行与密钥
文献检索	仅关键词检索出校园	第二道: 只带裸文件名与问题
深度文献	PaperQA2 全程在 HPC3	第三道: 语料不出校园
结果	HPC3 → 网关 → 浏览器	仅派生结果

工具的统一契约是: 接受数据集路径, 返回派生指标、图表文件路径或基因列表, 从不返回原始表达矩阵。

部署形态。生产环境为 eyeserver 上的 systemd 单元 bioagent.service，绑定节点 IP 的 :8800，前置无 selector 的 Kubernetes Service 与 Envoy Gateway。由于每个会话的 SSH 隧道与连接状态驻留在单进程内存中，部署采用 replicas: 1 与 Recreate 策略；生产数据库为 PostgreSQL 17 (SQLite 仅用于开发与 CI)；运行产物写入持久卷；会话 cookie 的签名密钥无默认值，管理员由 bcrypt 哈希播种。

3.2 智能体研究实验室

活跃的智能体系统是 src/bioagent/agents/ 中的角色化循环。三个角色共用同一套模型权重；区分它们的是脚手架——提示词、执行契约与确定性守卫。

角色	输入	产出
PI	研究问题 + 数据集画像 + 工具名册	有序议程
Scientist	单个步骤的简报	工具调用序列 + 最终答案
Critic	步骤描述 + 工具产物	accept / revise + 评分 + 具体批评
Coordinator	就绪任务集	下一个执行的任务 (DAG 模式)
专家	任务描述	按专长认领并执行 (DAG 模式)

数据集画像由系统在运行前确定性计算，包含每臂细胞数、每个细胞类型每臂细胞数、测序深度中位数与深度失衡标记、生物学重复判定、单细胞与单核协议推断。该画像与工具名册共同构成 PI 的规划输入。

单步执行契约。每个步骤内最多 8 次工具调用，每次调用后须读取结果再继续，并以 finish 返回最终答案。工具结果按条截断后进入上下文，使单步提示词规模可控。

确定性接受守卫。评审角色是模型，因此在其之外设置了一道不经模型的守卫：一个步骤，若其工具调用报错或返回空结果，Critic 无权 accept。该守卫是代码而非提示词，模型无法绕过，从而使「工具失败 → 评审通过 → 报告叙述未发生的分析」在结构上不成立。计划审阅另设四条成文规则：每个被指定的操作是否可计算；每个被承诺的产物是否真有步骤产生；步骤描述是否与其调用工具的实际行为一致；文献步骤是提问而非断言。

报告组装不经模型。循环收敛后：收集被接受的发现与工具实际写出的图表；由 _synthesize 写出叙述文字（唯一有模型参与的写作环节）；tools/report.py 经 pandoc → XeLaTeX 渲染 PDF、经 pandoc 渲染 DOCX；图表按工具产出的文件原样嵌入，无模型重绘数据图的环节；参考文献由被接受的引用确定性生成；过程细节与降级记录写入独立的技术报告，最终手稿保持干净。四层防幻觉依次为：正确的数据、闭集接地、数值格式与措辞规则、图注真实性检查。报告可在不重跑分析的前提下重新生成，单个分析步骤也可单独重跑。

计划修订采用打补丁而非重画。用户在 plan mode 中以自然语言给出修改意见，模型只返回 {"step": n, "new_text": ...}，由代码施加修改；未被提及的步骤因未被重新生成而不可能改变。仅当请求无法用单步编辑表达时才回落到整体重画。

DAG 规划、多智能体与专家记忆 (0.2.0 新增，特性开关化且纯增量)：结构化 pass 把议程转成带显式依赖的 LabPlan，就绪集调度器在前置完成时启动节点，每个节点获得受限简报；Coordinator 选取就绪任务，专家按专长认领；可变足迹不相交的分支可并行；每个专家持有私有的落盘记忆 (episodes.jsonl 与蒸馏出的 lessons.md)，在构造简报时召回、运行后反思更新，即在冻结权重上进行上下文内学习。

3.3 分析工具的实现

工具名册由 agents/registry.py 动态组装：scanpy 可用时轻量冒烟工具让位于真实分析线；注入相应 executor 后工具改为提交 HPC3 作业并保留进程内回落；未绑定 HPC 会话时文件系统工具为空而非提供会报错的工具。名册分为单细胞分析线、变异与表型线、文献线、代码与文件、元工具五类，共 30 余个具名工具，完整目录见补充材料 S2。

关键实现要点：run_clustering 可用自举重采样与调整兰德指数选择 Leiden 分辨率，取仍达稳定性阈值的最细值；run_de 输出列固定为 group, gene, log2fc, pval, pval_adj, score，支持按细胞类型分层的条件对比；run_pseudobulk_de 用 pydeseq2 的负二项 Wald 检验在样本层面聚合；run_depth_matched_de 将测序深度按分位数匹配到浅臂的逐细胞 UMI 分布后重跑同一检验，并按方向做 Spearman 相关；富集与 GSEA 均为离线实现，针对本地 .gmt 基因集；map_phenotype_to_hpo 由模型抽取短语与识别否定，而由本体拥有术语 ID，模型只能从候选中选取编号，因而不可能生成不存在的 HPO 术语。

3.4 模型评测设计

评测的核心设计是保持脚手架不变、只替换模型：每个实验臂都走真实的生产代码路径（直接调用 ResearchLab 的方法而非重新实现），在真实数据集（Ddx41_DEG.h5ad, 15,307 细胞）上运行，并调用真实工具。因此实验臂之间的差异归因于模型，而所有实验臂共有的表现归因于脚手架。

阶段	运行内容	保持不变的量	评价方式
A · 计划	ResearchLab._pi_plan	系统提示词、协议指引、数据集画像、工具名册	14 项确定性评分表 + 2 位盲评法官
B · 执行	_scientist → ResearchHarness → _critic, 逐步	同一份固定 7 步计划；工作区预置更早步骤产物；同一套人设	工具调用正确性、参数匹配、调用次数、收尾状态、评审接受率 + 盲评
C · 写作	_synthesize → _build_report → _review_report	同一批被接受的发现与图表	数值格式、措辞一致性、图表嵌入、事实性 + 盲评

盲评法官为 claude-opus-5 与 gemini-3.1-pro-preview，对作者臂盲评。评测代码为 experiments/plan_vs_exec_ab/run_ab.py，分 prep / A / B / C / judge / report 六个阶段运行。参评的九个模型见表 3.4.1。

评测条件。OpenRouter 上的 Qwen3.6 为 fp8 量化，生产为 AWQ 4-bit；本地运行工具无 Slurm 排队，故墙钟时间不可比；阶段 B 的固定计划由生产模型撰写，对所有实验臂一致；阶段 A 每臂 2–3 次重复，阶段 B 6–14 次试次，阶段 C 每提示词变体 2 次，因此结果给出的是量级与排序而非精确率。第一轮中因 API 额度上限未能完成的试次已从全部统计中剔除。

3.5 自托管容量与 GPU 台数估算方法

为回答「托管某个候选模型需要几张什么卡」，我们使用如下估算流程。

第一步：权重体积。NVFP4 量化为每权重 4 bit，另加每 16 个值一个 FP8 块尺度，合计约 4.5 bit/参数，即

$$W \approx 0.56 \text{ GB} \times P_{[\text{十亿参数}]}$$

该式为上界。我们自有的两份 NVFP4 权重实际更小（304B 模型的检查点为 126–127 GB，约 0.42 GB/十亿参数），因为非专家层占比很小且部分层保留 FP8。凡有实测检查点体积者，表中使用实测值。

第二步：服务所需的聚合显存。权重之外还须容纳激活、CUDA graph 捕获、MoE 路由缓冲与一个可用的 KV 池。我们用自有的两个实测点标定这一系数：

- Qwen3.6-35B-A3B（权重 20 GB）在单张 96 GB 卡上服务，且留出 58.8 GiB 的 KV 池；
- DeepSeek-V4-Flash-0731（权重 127 GB）在 96 GB 卡上须 **TP=4**，TP=2 实测显存不足。

由 TP=2（192 GB 聚合）不足而 TP=4（384 GB 聚合）可用，可得所需聚合显存介于 $1.5\times$ 与 $3.0\times$ 权重之间；取

$$V_{\text{需要}} \approx 1.8 \times W$$

作为工作估计，它与上述两个实测点一致（Qwen3.6: $36 \text{ GB} \leq 96 \text{ GB}$ ，单卡；DSV4-Flash: 229 GB，96 GB 卡需 3 张，向上取整至 TP=4）。另有两个实测部署与之相符：MiniMax-M2.7 的 FP8 权重（220 GB）与 MiniMax-M3 的 NVFP4 权重（228 GB）均在同一 384 GB 节点上以 TP=4 加载，分别相当于 1.75 倍与 1.68 倍权重体积，故 1.8 倍是安全的规划系数，偶尔会保守一档。

第三步：设备台数。台数为

$$N = \lceil V_{\text{需要}} / C_{\text{单卡}} \rceil$$

再向上取整至一个合法的张量并行度。vLLM 与 SGLang 要求张量并行度整除注意力头数，实践中取 1、2、4、8、16。

第四步：互联。RTX PRO 系列为 PCIe 连接、不提供 NVLink，因此在同等台数下其张量并行的扩展效率低于具备 NVLink 的 HGX B200/B300 系统。台数表回答的是「能否装下」，不是「吞吐相同」。

参与估算的在售 Blackwell 设备及其单卡显存如下（厂商公布值；96 GB 一档为我们实测使用的设备）。

设备	类别	单卡显存	互联
RTX PRO 4500 Blackwell	工作站	32 GB GDDR7	PCIe
RTX PRO 5000 Blackwell	工作站	48 GB GDDR7	PCIe
RTX PRO 6000 Blackwell （工作站 / Max-Q / 服务器版）	工作站 / 服务器	96 GB GDDR7	PCIe
NVIDIA B200	数据中心（HGX）	180 GB HBM3e	NVLink 5
NVIDIA B300（Blackwell Ultra）	数据中心（HGX）	288 GB HBM3e	NVLink 5

B200 的单卡容量在不同资料中有 180 GB 与 192 GB 两种表述；本文取较保守的 180 GB。

3.6 机制验证的设计

除单元测试外，四项关键机制在已知答案或真实服务模型上做了独立验证，设计如下，结果见 3.6。

计划修订保真度。同一模型、同一份计划、4 个修改请求 × 5 次重复，在真实 vLLM 服务的 Qwen3.6 上比较整体重画与代码打补丁两种实现。指标为目标步骤是否命中、意图是否达成、其他步骤被改动的数量、步数是否变化。评分器先用合成的「完美 / 附带改动 / 丢步 / 空操作」计划自检。

深度匹配工具的已知答案验证。构造答案已知的合成数据：每个细胞类型 800 细胞、300 基因，MUT 臂每细胞深度约为 WT 的 2 倍。RealBio 类型含 30 个表达比例确实高 3 倍的基因（正确判定为「保留」），DepthOnly 类型两臂比例完全相同（正确判定为「不保留」）。该验证共跑过两次：2026-08-20 一次，2026-09-02 在修复基因选择、稳健性阈值位置与两个方向的处理方式之后再跑一次。第二次是当前结果，也是下文所报告的结果。

多智能体会议的证据分配。同一场解读会议、同样六条发现、同样三位专家、同样的综合提示词，唯一变量为每位专家看到全部证据还是各拿一片。六条发现刻意包含一个强的逐细胞信号与一个限制其解释的设计事实。每臂 n=1，作为机制示例。

可审计协议格式。为变异注释流水线编写 operon 风格的 PROTOCOL.md（摘要表与每步可折叠详情：做什么、为什么、agent 选择的参数、真实命令、验证清单），命令取自真实源码；以同一套规划提示词对新旧两种文档做 A/B，按 11 分制确定性评分，另加 LLM 法官与可读性评分。

4 结果

4.1 已部署的能力

下表列出已建成的能力及其在生产环境中的启用状态。

能力	已建成	生产启用
Web 控制台（账号、SSH/Duo、Slurm vLLM、隧道、GPU 隔离、中途自动恢复）	是	是
线性 PI→Scientist→Critic 实验室	是	是
真实 scanpy/gseapy 分析线	是	是
代码沙箱（CodeAct）	是	是
确定性 pandoc PDF/DOCX 报告，支持不重跑重生成	是	是
文献线（Europe PMC + PaperQA2）	是	是
服务端聊天历史与可续传上传	是	是
表型线（HPO 映射 + LIRICAL + 鉴别诊断）	是	是
专家演化记忆	是	是
用户自带 LLM API key	是	是
快速 Chat 路径与内联 Mermaid	是	是
计划打补丁式修订	是	是
深度匹配验证工具	是	是
DAG 规划器	是	可选
真多智能体与专家认领	是	可选
安全并发	是	可选
离线 VEP 变异线	是	可选
scGPT 逐细胞注释	是	可选
视觉模型复核渲染结果	是	可选
LangGraph 执行外壳	是	可选
假设驱动探索 / 多周期循环 / 技能归纳	是	可选
模型评测框架	是	—

规模指标：39,916 行 Python（97 个文件、8 个子包）、1,611 条离线测试（无需集群、.env 或网络）、675 次提交（自 2026-06-08 起）、5,244 行前端、15 个原子技能、7 条预设流水线。

4.2 覆盖的研究场景

系统当前覆盖九类研究任务。

场景一：条件对比的单细胞差异表达研究（预设流水线 differential_expression）。KO 对 WT、疾病对对照、处理对未处理的 snRNA-seq / scRNA-seq 数据集。完整链路为：

步骤	工具	实现要点
数据画像	inspect_dataset	确定性计算每臂细胞数、每细胞类型每臂细胞数、深度中位数、重复数判定、单细胞/单核协议推断
质控	run_scanpy_qc	逐细胞指标、细胞与基因过滤、归一化、log1p、高变基因选择；写质控图与检查点
双细胞	run_doublet_detection	Scrublet，在质控之后、聚类之前
批次整合	run_integration	对象含多样本时校正供体与批次效应
聚类	run_clustering	PCA → 邻接图 → Leiden → UMAP；可用自举稳定性自动选分辨率

步骤	工具	实现要点
差异表达	run_de	Wilcoxon 秩和检验；给定对照层级做条件对比，给定细胞类型列在每类内分别做
聚合检验	run_pseudobulk_de	聚合到每样本一条谱，pydeseq2 负二项 Wald 检验
深度校正	run_depth_matched_de	分位数匹配 UMI 深度后重跑同一检验，按方向做 Spearman 相关
组成变化	run_composition	各细胞类型在各样本中的占比与条件间迁移
通路	run_enrichment / run_gsea_prerank	离线 ORA 与预排序 GSEA，按组、按方向分别进行
文献落地	literature_search / deep_literature	由被接受的发现构建检索式，产出带引用的结论
手稿	报告组装	pandoc → XeLaTeX 的 PDF 与 DOCX，图表原样嵌入

场景二：无标签数据集的细胞类型注释 (celltype_annotation、scgpt_annotation)。稳定性选分辨率把「分辨率」从未审视的假设变为有据可依的选择；run_marker_annotation 按 marker panel 指派细胞类型并支持谱系特异判别基因；scgpt_annotate 以独立的短时 GPU 批作业为每个细胞给出标签与置信度；数据集若已带标签则复用而不重算。

场景三：遗传眼病与罕见病的变异解读 (variant_annotation)。生产路径为 HPC3 上的离线 VEP 加本地 cache，以容器化 Slurm 作业运行，可处理 WGS 规模 VCF；注释包含功能后果、受累基因、预测影响与 ClinVar 临床意义；致病性预测插件为 CADD、REVEL、AlphaMissense 与 OpenSpliceAI；基因组版本以 VCF 头自动检测；工具链容器内置 bcftools 1.21、samtools、tabix、bedtools 与 pysam/cyvcf2。

场景四：表型驱动的鉴别诊断 (phenotype_variant_diagnosis)。map_phenotype_to_hpo 将任意语言的自由文本转为经校验的 HPO 术语；run_lirical 调用 LIRICAL 2.4.1 按校准过的验后概率排序候选疾病；diagnose_disease 将该概率与 PaperQA2 的文献证据结合，产出裁决过的鉴别列表。

场景五：基因特征打分与扰动分析 (gene_signature_scoring、perturbation_analysis)。含逃逸细胞过滤、扰动对对照差异、e-distance 效应量与分层比较。

场景六：文献落地与可引用产出。关键词检索式在运行时由被接受的发现构建而非由用户问题模板化生成；深度检索全程在 HPC3 上以本地模型与本地 embedding 完成；参考文献段落由被接受的引用确定性生成。

场景七：快速问答。Chat 路径以一份手挑的短名单工具（文献检索、HPO 映射、深度文献）提供秒级回答，入选门槛为进程内运行、秒级返回、不需运行工作区与 Slurm 作业。该名单与研究路径共用同一批工具定义，因而不会在两条路径之间漂移。

场景八：合规的计算与数据放置。上传直达用户自己的 HPC3 目录，网关不留副本；传输走专用传输节点而计算与隧道留在登录节点；GPU 作业按用户隔离；per-run 过程文件集中于共享临时目录并按 3 天周期清理。

场景九：自带模型端点。用户可添加自己的 OpenAI 兼容端点与密钥替换会话模型，密钥在服务端加密存储；HPC3 账号仍然必需，因为分析作业运行在集群上。

4.3 分析产出示例

以下取自真实运行 c135ae589d96 (2026-09-02)，数据为实验室自有的 DDX41 视网膜单核 RNA 测序数据。

项目	值
数据	Ddx41_DEG1.h5ad, 15,307 细胞 × 33,696 基因
设计	sampleid 两个水平 (DDX41 6,260 / WT 9,047)
标签	文件自带 majorclass (11 类) 与 celltype (87 类)，复用而非重算
产出	12 页手稿 PDF、DOCX、技术报告、26 张图、80 余张表
渲染	pandoc → XeLaTeX

手稿结构为：摘要、数据集、运行内容、研究问题、结果（质控、聚类、差异表达、通路富集、深度匹配验证与 pseudobulk、组成与文献落地）、讨论、局限、结论、方法、参考文献。

其中「运行内容」一节是可复现性的核心：每个分析归属到执行它的具名工具，参数逐条列出并解释其含义，凡非默认值均标注为本轮选择。例如本轮质控的线粒体比例上限被设为 5% 而非组织常用的 10%，理由写明为数据被判定为单核（存在核比例列且线粒体中位数仅 1.5%），细胞核几乎不应携带线粒体信号。

Single-cell transcriptomic profiling of DDX41-depleted retinal nuclei reveals depth-driven transcriptional shifts


Contents

Abstract	1
The dataset	2
What was run	3
Study question	5
Results	5
Quality control	5
Cell clustering	6
Differential expression	7
Pathway enrichment	9
Depth-matched validation and pseudobulk	9
Cell-type composition and literature grounding	10
Discussion	10
Limitations	11
Conclusion	11
Methods	11
References	12

Abstract

DDX41 is a conserved splicing factor implicated in photoreceptor maintenance and retinal dystrophy, yet its precise transcriptional impact on non-photoreceptor retinal subtypes remains uncharacterized at single-cell resolution. We profiled a single-donor, snRNA-seq dataset comparing DDX41-depleted retinal nuclei to wild-type (WT), processing 15,307 high-quality nuclei through quality control, stability-selected Leiden clustering, stratified Wilcoxon contrasts, depth-matched validation, pseudobulk aggregation, and over-representation/preranked gene set enrichment analysis. The dataset resolved 20 transcriptional clusters aligning with 11 annotated retinal major classes, with initial stratified contrasts yielding thousands of genes exhibiting large effect sizes across five cell types. However, depth-matched differential expression revealed that zero of eight cell-type direction rankings survived UMI equalization (Spearman $\rho < 0.5$), and three rankings completely inverted, while pseudobulk aggregation returned zero statistically supported genes. Pathway shifts were dominated by translational and metabolic processes, but these signals are conditional on descriptive rankings confounded by a 1.1–1.7 $\times$ sequencing depth imbalance. Consequently, all observed transcriptional and pathway-level shifts are framed as descriptive effect-size hypotheses rather than validated regulatory outcomes. Independent validation using donor-replicated snRNA-seq, matched sequencing depth, and orthogonal molecular assays is required to distinguish technical

图 1: 样例手稿首页：标题、目录与摘要



mixed clusters.


Differential expression

The core take-home message is that initial stratified contrasts identify genes with large descriptive effect sizes across five major classes, but these rankings are highly sensitive to sequencing depth imbalance and do not represent validated differential expression. Stratified Wilcoxon contrasts with `groupby='sampleid'`, `reference='WT'`, and `stratify_by='majorclass'` were applied to five major classes meeting the minimum 30-cells-per-arm threshold: AC, BC, Cone, MG, and Rod. Six classes were excluded from analysis due to falling below the stability threshold. The genes with the largest positive and negative log2 fold-changes in each class are summarized below:

majorclass	total_sig	up_regulated	down_regulated	total_genes_tested	min_abs_log2fc	max_abs_log2fc
AC	515	374	140	8371	0.30	4.91
BC	1910	1463	284	7309	0.22	3.83
Cone	383	329	53	6840	0.38	5.99
MG	7182	5028	508	9720	0.48	26.32
Rod	4350	3279	107	4649	0.51	8.74

Volcano plots displaying genes past the descriptive threshold for each class are shown below:

图 2: 样例手稿第 7 页: 20 个 Leiden 簇的 UMAP 与按细胞类型分层的差异表达汇总表



Pathway enrichment

The core take-home message is that coordinated pathway shifts in translation and metabolism are detected by ORA and preranked GSEA, but these signals are conditional on descriptive, depth-confounded rankings and should not be interpreted as validated biological pathways. Overrepresentation analysis tested up- and down-regulated gene halves ($|\log_2 \text{fold-change}| \geq 0.25$) against GO, Reactome, and Hallmark libraries. Preranked GSEA walks on Wilcoxon-statistic ranked lists identified coordinated shifts. In BC, genes with the largest positive $\log_2$ fold-changes enriched for translation-related terms, while genes with the largest negative $\log_2$ fold-changes enriched for phototransduction (NES -2.7). In Cones, down-regulated rankings showed strong depletion of carbohydrate catabolic and visual perception pathways (NES -3.1). MG and Rod rankings similarly highlighted translational elongation and phototransduction cascades. These enrichment p-values are descriptive overlap statistics computed on a possibly depth-confounded ranking; they report the strength of gene-set overlap but do not confirm that the underlying expression changes are biological.

Depth-matched validation and pseudobulk

The core take-home message is that sequencing depth artifacts fully explain the initial differential expression and enrichment signals, as depth equalization collapses all rankings and pseudobulk aggregation yields zero supported genes. The DDX41 libraries sampled 1.1–1.7 $\times$ deeper UMIs per cell than WT. After down-sampling to match WT distributions within each major class, Wilcoxon contrasts were re-run. Zero of eight cell-type $\times$ direction rankings survived depth matching (Spearman $\rho < 0.5$), and three rankings completely inverted, indicating pure detection artifacts. Pseudobulk aggregation (summed raw counts $\rightarrow \log_2 \text{CPM} \rightarrow \text{Welch t-test}$) yielded zero significant genes across all tested classes, con-

9

图 3: 样例手稿第 9 页: Rod 火山图、通路富集与深度匹配验证

单次运行产出的图表均由 scanpy 与 matplotlib 确定性绘制并按原文件嵌入手稿，无模型参与作图。补充材料 S9 给出更多图例。



图 4: schematic 工具输出的确定性 workflows，记录本轮实际执行的步骤链

深度匹配验证的实际效果。初始分层对比在五个细胞类型中给出的效应量为：

majorclass	显著数	上调	下调	测试基因数	平均 abs log2FC	最大 abs log2FC
AC	515	374	140	8,371	0.30	4.91
BC	1,910	1,463	284	7,309	0.22	3.83
Cone	383	329	53	6,840	0.38	5.99
MG	7,182	5,028	508	9,720	0.48	26.32
Rod	4,350	3,279	107	4,649	0.51	8.74

深度匹配后的复核显示：两臂每细胞 UMI 中位数相差 1.1–1.7 倍 (DDX41 3078、WT 1916)；八个「细胞类型 × 方向」排名在 UMI 均衡后均未保持 (Spearman $\rho < 0.5$)，其中三个方向反向；pseudobulk 聚合在所有被测类型上未返回统计支持的基因。系统据此将结果表述为描述性假设，并在局限一节写明需要供体重复、匹配深度与正交分子实验。这正是该能力的作用：在结论进入手稿之前，先把深度效应与生物学分离。

关于如何阅读这一判定，有一点需要说明。本次运行的报告写于 2026-09-02 18:36，而方法一节与 4.6 所述的方向修复在同日晚间才落地，因此该运行使用的是较早版本的工具——对上下两个方向使用同一个 ρ 阈值，并把两个方向都视为可检验。按当前工具，四个下调方向的排名会被报为 `against_depth_untestable` 而不计为失败，于是「八个排名均未保持」这一表述在今天应读作：四个可检验的上调排名均未保持，四个下调排名既未被验证也未被否定。上调方向的结论不变。




图 5: run_depth_matched_de 输出的深度匹配相关性

4.4 模型评测结果

4.4.1 参评模型

实验臂	模型	说明
qwen36-35b	qwen/qwen3.6-35b-a3b	生产 Scientist 循环（思考关）
qwen36-35b-think	同上	生产 PI / Critic / 写作者（思考开）
qwen35-122b	qwen/qwen3.5-122b-a10b	更大的开源权重
deepseek-v4-pro	deepseek/deepseek-v4-pro	强开源权重
sonnet-5	anthropic/claude-sonnet-5	前沿参照
gpt-5.4	openai/gpt-5.4	前沿参照
minimax-m2.7	minimax/minimax-m2.7 (229B-A10B)	自有节点候选
minimax-m3	minimax/minimax-m3 (428B-A23B, 多模态)	自有节点候选
deepseek-v4-flash	deepseek/deepseek-v4-flash-0731 (304B, MIT)	自有节点候选
laguna-s-2.1	poolside/laguna-s-2.1	前两轮之后追加；仅参与阶段 A 与 B

4.4.2 阶段 A：计划质量

实验臂	n	步数	评分表	幻觉工具	深度意识	重复数意识	法官：科学性	具体性	数据契合	秒
qwen36-35b	3	8.33	0.91	0	0%	100%	6.00	6.83	7.50	24.9
qwen36-35b-think	3	7.67	0.98	0	67%	100%	7.17	7.67	8.17	285.0
qwen35-122b	3	9.00	0.94	0	33%	100%	6.33	7.33	8.00	13.2
deepseek-v4-pro	3	11.00	0.93	0	100%	100%	8.50	9.17	9.50	44.8
sonnet-5	3	11.33	0.98	0	100%	100%	9.50	9.50	10.00	79.8
gpt-5.4	3	15.67	0.83	0	100%	100%	9.33	9.33	9.67	29.6
minimax-m2.7	2	9.00	1.00	0	100%	100%	8.50	8.50	8.75	53.9
minimax-m3	2	11.00	1.00	0	100%	100%	9.25	9.50	9.75	252.4
deepseek-v4-flash	2	10.00	1.00	0	100%	100%	9.50	9.50	9.75	162.6
deepseek-v4-flash-low	2	8.00	0.97	0	100%	100%	9.50	9.50	9.75	41.8
laguna-s-2.1	3	6.33	0.89	0	100%	100%	9.33	9.33	9.83	156.3

基础项（分层差异表达、组成分析、富集在差异表达之后、生物学重复警告、不虚构工具）为所有实验臂全部达成。区分度出现在需要判断力的项，即计划是否处理了数据集画像中标记的深度失衡，且随模型能力单调变化。

4.4.3 阶段 B：执行同一份计划

实验臂	试次	调用了指名工具	成功	参数匹配	沙箱调用/步	侦察/步	非空答案收尾	评审接受
qwen36-35b	14	86%	86%	1.0	3.36	3.79	29%	71%
qwen36-35b-think	14	93%	93%	1.0	3.00	3.79	36%	93%
qwen35-122b	12	92%	92%	1.0	1.42	4.92	17%	92%
deepseek-v4-pro	6	67%	67%	1.0	2.33	5.00	50%	67%
minimax-m2.7	14	93%	93%	1.0	4.00	2.50	50%	71%
minimax-m3	14	93%	93%	1.0	2.93	5.71	43%	79%
deepseek-v4-flash	14	86%	86%	1.0	4.43	4.86	21%	79%
deepseek-v4-flash-low	14	86%	86%	0.9	4.36	3.79	21%	71%
laguna-s-2.1	14	57%	57%	1.0	2.00	8.79	14%	29%

除一个实验臂外，工具调用的正确性都很高：86–93% 的步骤调用了步骤指名的工具，且只要调用，参数匹配率均为 1.0（DeepSeek-V4-Flash 低推理档为 0.9）。差异集中在调用完成后的收敛行为，MiniMax-M2.7 的侦察性调用最少（2.50/步）、非空收尾率最高（50%）。代码一次跑通的比例为 MiniMax-M3 95%、DeepSeek-V4-Flash 90%、MiniMax-M2.7 86%、Qwen 79–82%。

唯一偏离这一模式的是前两轮之后追加的 laguna-s-2.1：它只在 57% 的步骤里调用了步骤指名的工具，每步发起 8.79 次侦察性调用（是 MiniMax-M2.7 的三倍以上），仅 14% 的步骤以非空答案收尾，评审接受率 29%，为所有实

实验臂最低。而它的规划能力很强——阶段 A 法官科学性 9.33、数据契合 9.83，且议程最短（6.33 步）。这正是本设计意在分离的「会规划、不会执行」的清晰个例。该实验臂未参与阶段 C。

4.4.4 阶段 C：写作同一批发现

实验臂	n	字符数	「significant」 断言	提到深度	法官：提出假 象可能	重复数一致	编造	质量
qwen36-35b	2	21,501	4.0	1	25%	100%	25%	4.25
qwen36-35b-think	2	22,309	0.0	3	75%	75%	75%	5.50
qwen35-122b	2	24,581	4.0	1	0%	100%	50%	3.25
deepseek-v4-pro	2	28,469	4.0	2.5	75%	100%	100%	4.75
sonnet-5	2	23,818	2.0	9	100%	100%	0%	8.50
minimax-m2.7	2	41,739	6.5	9.5	75%	100%	100%	4.50
minimax-m3	2	27,967	3.0	4.5	100%	100%	50%	7.50
deepseek-v4-flash-low	2	26,003	2.0	9.5	100%	100%	0%	8.00

(laguna-s-2.1 与 gpt-5.4 未参与阶段 C。)

写作阶段的提示词规则（数值格式、重复数措辞、描述性差异表达、图注真实性）对所有实验臂均生效，消除了科学计数法与虚构图注一类的机械错误；判断力层面的差异由模型能力决定。另一项可操作结论是：推理型模型需要与其思考量匹配的输出预算——DeepSeek-V4-Flash 在低推理档配 6 倍输出预算下达到 8.0，为仅次于 Sonnet 5 的写作者。

4.5 GPU 托管需求

按 2.5 的方法估算，各候选模型在五类在售 Blackwell 设备上所需的 GPU 台数如下。表内为「台数（张量并行度）」；台数已向上取整至合法的张量并行度。

模型	参数（总 / 激活）	NVFP4 权重	所需聚合显存	RTX PRO 4500 32 GB	RTX PRO 5000 48 GB	RTX PRO 6000 96 GB	B200 180 GB	B300 288 GB
Qwen3.6-35B-A3B (生产)	35B / 3B	20 GB	36 GB	2 (TP2)	1	1 [实测]	1	1
Qwen3.5-122B-A10B	122B / 10B	68 GB	123 GB	4 (TP4)	3 → 4 (TP4)	2 (TP2)	1	1
MiniMax-M2.7	229B / 10B	128 GB (FP8: 220 GB [实测])	231 GB	8 (TP8)	5 → 8 (TP8)	4 (TP4) [实测]	2 (TP2)	1
MiniMax-M3	428B / 23B	228 GB [实测]	384 GB [实测]	12 → 16	8 (TP8)	4 (TP4) [实测, 可加载]	3 → 4 (TP4)	2 (TP2)
DeepSeek-V4-Flash-0731	304B / 13B	127 GB [实测]	229 GB	8 (TP8)	5 → 8 (TP8)	3 → 4 (TP4) [实测]	2 (TP2)	1
DeepSeek-V4-Pro	未公开	—	—	—	—	—	—	—
Claude Sonnet 5 · GPT-5.4	闭源	—	—	不可自托管				

说明：

- [实测] 标记的两格为我们在真实硬件上验证过的配置：Qwen3.6-35B-A3B 在单张 RTX PRO 6000 96 GB 上服务并留出 58.8 GiB KV 池；DeepSeek-V4-Flash-0731 的 NVFP4 权重在 4 张 96 GB 卡上以 TP=4 服务（SGLang 0.5.18 配 `--moe-runner-backend marlin`，512 K 上下文，约 78 tok/s），TP=2 显存不足。
- 「3 → 4」表示算术台数为 3，但张量并行度须为 2 的幂，故实际部署 4 张。
- MiniMax-M2.7 的实测部署使用官方 FP8 权重（磁盘 220 GB，TP=4 时每卡约 55 GB），而非 NVFP4 检查点；两种基准在 96 GB 一档都落到 4 张卡。
- MiniMax-M3 的 NVFP4 检查点实测为 **228 GB**（88/88 分片校验通过），在 4×96 GB 节点上以 TP=4 可加载，即 1.68 倍权重体积——低于 1.8 倍的规划系数，故对该模型本估算保守了一档。M3 的约束不在显存，见下方服务栈说明。
- 表中未计入多用户并发。若需同时服务多个会话，KV 池须按并发数放大；Qwen3.6 的混合注意力使其 KV 成本极低（约 20 KiB/token，见下），而常规稠密 GQA 模型的每 token 成本通常高出数倍。

我们当前可获得的上限。free-gpu32 分区对整个 ruic20_lab 账号提供 4 张并发 GPU，节点为每台 4 张 RTX PRO 6000 96 GB（32 CPU / 257 GB 内存），即聚合 **384 GB**。由上表，Qwen3.6-35B、Qwen3.5-122B、MiniMax-M2.7 与 DeepSeek-V4-Flash 均可在该上限内托管，MiniMax-M3 的 NVFP4 检查点同样可在该上限内以 TP=4 加载——M3 的障碍在服务栈而非显存（见下）。该分区免费但为抢占取消模式、最长 3 天；付费 gpu 分区不可抢占、最长 14 天，96 GB 卡按 2 倍服务单元计价。

KV 与上下文的实测。生产模型 Qwen3.6-35B-A3B 为混合注意力，layer_types 除每第 4 层外均为线性注意力，40 层中仅 10 层持有 KV cache，约 20 KiB/token。因此 262 K 满长上下文的 KV 仅需约 5 GiB，1 GB KV 约合 5.1 万 token；max_position_embeddings 原生即 262,144。2026-08-02 在真实集群上的实测：

卡	分区	KV cache	tokens	262 K 满长并发
A100 80 GB PCIe (sm_80)	gpu（付费）	47.8 GiB	2,466,442	9.41×
RTX PRO 6000 Blackwell 96 GB (sm_120)	free-gpu32（免费）	58.8 GiB	3,035,461	11.58×

NVFP4 服务栈。DeepSeek-V4-Flash 的 NVFP4 权重在 sm_120 上可用 SGLang 0.5.18 配 `--moe-runner-backend marlin` 于 TP=4 服务（512 K 上下文，约 78 tok/s，工具调用正确）；原版 vLLM 0.28.0 在 TP=4 与 131 K 上下文下亦可无补丁运行。

MiniMax 服务栈（实测）。MiniMax-M2.7 的官方 FP8 权重（磁盘 220 GB，TP=4 时每卡约 55 GB）在 sm_120 上可用 **vLLM 0.22.1** 配 `--tool-call-parser minimax_m2` 于 TP=4 服务，/v1/models 报告的上下文为 **196,608 token**，对话与工具调用均已验证。vLLM 0.27.1 与当前 nightly 会在预热前向传播中无限挂起（四张 GPU 满载 100% 持续 4 小时以上），因此版本必须钉在 0.22.1。MiniMax-M3 的 NVFP4 检查点（228 GB，88/88 分片校验通过）在同一 4×96 GB 节点上以 TP=4 可加载并起服务，但在所有稳定版 vLLM 上产生确定性的损坏输出：M3 的 NVFP4 支持位于 `vllm-project/vllm#46380`，尚未进入稳定发行版，且稳定分支是静默失败而非报错。作为对照，Llama-3.1-8B-FP4 在同一节点同一镜像上于 TP=1 与 TP=4 均输出正确，说明硬件、FP4 反量化与张量并行本身都没有问题。

4.6 机制验证结果

计划修订保真度。

实现	干净	有附带改动	平均附带改动	步数变化	意图达成
整体重画（n=19）	0%	100%	3.89	89%	53%
代码打补丁（n=19）	100%	0%	0.00	0%	100%
生产实现（打补丁，n=20）	100%	0%	0.00	0%	100%

打补丁框架不仅消除了附带改动，意图达成率也从 53% 升至 100%。该结果同时表明在计划编辑这一环节上采用更大的模型不会带来收益，生产实现据此定型。

深度匹配工具的已知答案验证（2026-09-02，在选择、稳健性与方向修复之后；HPC3 分析容器）。

细胞类型	方向	Spearman ρ	判定
DepthOnly	up	0.15	weak —— 正确地判为未保留
DepthOnly	down	-0.05	against_depth_untestable
RealBio	up	0.84	preserved
RealBio	down	0.32	against_depth_untestable

基因层面：RealBio 上调方向保住 **30** 个中的 **27** 个真正变化的基因，背景 **0/30**；此前的判据保住 30/30，但同时放过 3/30 背景，因此现在的特异性是完美的，代价是三个真基因。DepthOnly 上调放过 54 个纯背景基因中的 19 个——在那里起保护作用的是排名判定 weak，而不是基因计数。

两个方向中只有一个可检验，工具现在会明说。深度会抬高深测序臂的检出率，因此它只能在该臂制造出「上调」的假象。下调方向逆着这一梯度，低 ρ 因而不构成假象的证据；但对深测序臂做降采样又会把每个基因都推向「更下调」，所以这项检查同样无法确认这些基因：本次实测中，一条「效应存活」规则在 RealBio 下调方向上于 0.5 阈值放过 92% 的纯背景、0.8 阈值放过 73%。工具因此对该方向报 against_depth_untestable 并且完全不给稳健性计数，而不是给出一个会为噪声背书的数字。下调方向的基因在这项检查里既未被验证也未被否定。

稳健性阈值设在 Wilcoxon z 上，**0.8** 是扫出来的而非选定的。阈值取 0.5、0.6、0.8、1.0 时，30 个真基因分别保住 30、30、27、7 个，背景始终为 0/30；而纯深度对照分别放过 50%、43%、35%、28%。

多智能体会议的证据分配。共享证据时，讨论集中于一般方法论，并引用了 scVI、MAST、DESeq2 等不在证据中的方法；分片证据时，讨论锚定于本研究的证据，各方明确引用自己看过的表，形成有信息量的位置性分歧，综合环节的产出也随之从通用规则变为针对本数据集的具体判断。

可审计协议格式。新格式在规划质量不降的前提下显著提升可审计性，代价约 36% 的提示词 token。据此确立的设计原则为：可读文档必须是真正运行代码的一个投影，由源码生成并加持持续集成的过期检查，而非手工分叉的副本。

5 讨论

模型选型。系统已内建角色分流能力（BIOAGENT_LAB_LLM_*），可为不同角色配置不同模型。综合三个阶段的评测：

角色	建议模型	依据
PI 与写作者	DeepSeek-V4-Flash-0731	计划 9.5（并列最高）、写作 8.0（第二）、MIT 许可、成本最低；须配低推理档与不低于 32 k 的输出预算
Scientist 循环	MiniMax-M2.7	执行行为最好：侦察调用最少、非空收尾率最高；交错思考为工具调用设计；且是唯一已在自有节点上验证过服务的候选（FP8、TP=4、vLLM 0.22.1、196,608 token 上下文）

托管路径。上述两个模型在当前可获得的 4 张 RTX PRO 6000（聚合 384 GB）上均可托管，各需 4 张（TP=4）；其中 MiniMax-M2.7 是实测而非估算：其官方 FP8 权重已在 vLLM 0.22.1 下以 TP=4 起服务，上下文 196,608 token，工具调用验证通过。若两个角色需同时在线，则需 8 张卡或改用单卡容量更大的数据中心设备——B200 一档两者各需 2 张，B300 一档各需 1 张。评测数字上最均衡的 MiniMax-M3 同样能在这 384 GB 内以 TP=4 加载，因此它的障碍不是显存而是服务栈：M3 的 NVFP4 支持尚未进入稳定版 vLLM，稳定分支会静默返回损坏输出。需要注意 RTX PRO 系列为 PCIe 连接、不提供 NVLink，因此同等台数下其张量并行扩展效率低于 HGX 系统；台数表回答的是能否装下，而非吞吐相同。

方法学。让实验臂走真实生产代码路径而非重新实现，是本评测设计的关键：它使「差异归因于模型、共性归因于脚手架」这一推断成立，也使评测结论可以直接转化为配置变更。同样地，用已知答案的合成数据验证 run_depth_matched_de，是单元测试无法替代的一步——单元测试能证明代码按设计运行，不能证明设计在科学上正确。

适用范围。本文的评测在单一数据集与单一研究问题上进行，重复次数为 2–3 次，因此结论给出的是量级与排序。GPU 台数表基于厂商公布的单卡容量与一个由两个实测点标定的系数，用于容量规划而非性能预测。

补充材料

S1 操作指南

前置条件

条件	说明
AiScientist 账号	由管理员创建；自助注册若开启，仅接受 @uci.edu 邮箱并需邮件验证码
网络	UCI 校园网或 VPN
HPC3 账号	必须有；即使自带模型密钥，分析作业仍在用户自己的 HPC3 账号下运行
浏览器	支持 WebSocket 的现代浏览器

登录与连接 HPC3

访问 <https://aiscientist.eye.som.uci.edu/> 并输入用户名与密码。数据库只存应用密码的 bcrypt 哈希，HPC3 凭据不落库。

在 Research 页的「CONNECT TO HPC3」区域连接，三种方式：

- 密码加 **Duo**：填写 UCInetID 与密码，选择 Duo 方式（推送、电话、验证码）；可勾选 Remember me 在 HPC3 上建立可复用的 SSH key，下次免密码免 Duo；勾选校园网确认后连接。
- 已保存的 **SSH key**：在下拉框选择已保存的密钥，有口令则填写。私钥存放在服务端，权限 0600、按用户隔离。
- 自带模型端点：LLM endpoint 默认为集群 GPU；可添加自己的 OpenAI 兼容端点与密钥。

连接成功后系统拉起 per-user 的 Slurm GPU 作业托管模型并在连接时预热。Mock mode 提供不连集群的演示模式。




图 6: Research 页。左栏上方为连接的六个阶段（SSH 登录、vLLM 检测与镜像、GPU 分配、vLLM 服务与隧道、模型就绪、Live），下方为服务端保存的历史会话；右下为运行控件。

上传数据集与发起运行

上传分块且可断点续传，文件直接流入 /dfs3b/ruic20_lab/<UCInetID>/uploads/。一次运行可绑定多个数据文件。

控件	选项	含义
执行路径	Research（完整管线）	完整研究管线，产出手稿
	Chat（快速回答）	快速问答，秒级返回
团队形态	Auto（PI 决定）	由 PI 决定单或多智能体（默认）
	Single agent	强制单智能体
	Virtual Lab	强制多智能体
人工闸门	Plan first	PI 先提计划，聊天中细化后执行（默认）
	Bypass	跳过人工闸门自主运行

Advanced 可搜索并强制指定预设流水线，默认由 PI 自选。

Plan mode

勾选 Plan first 时，PI 先产出议程并暂停。逐条阅读后在聊天里用自然语言提出修改意见，无需手工编辑文本；系统按打补丁机制施加修改。确认后开始执行，进度按角色逐 token 流式回传。

查看与获取结果

结果面板提供渲染后的报告、全部图、全部表，以及完整结果包下载。两个后续操作：Ask the PI to revise the report 只重写报告不重跑分析；Ask the PI to re-run an analysis step 重跑指定分析步骤。




图 7: 结果面板：结果包下载、重生成报告、重跑步骤、文件浏览，以及本次运行产出的 11 个报告文件与 27 张图的清单。




图 8: Runs 页：服务端保存的历次运行与其状态，完成的运行提供结果包下载。

服务端产物路径为：

```
runs/console/<UCInetID>/<run_id>/
  figures/      图 (PNG)
  tables/      表 (CSV)
  report/      report.md/.pdf/.docx · technical_report.* · plan.md
  process/     run_state.json 等过程记录
  data/        检查点
```

管理与本地开发

命令行工具 `bioagent-admin` 提供 `create-admin`、`reset-password`、`list-users`、`hash-password`。界面中的 Admin 页提供账号管理，System 页显示工具名册与运行环境。

```
./deploy.sh          # 创建 venv 并安装 (幂等)
./start.sh           # 绑定 127.0.0.1:8800
python3 -m pytest    # 1,611 条离线用例，无需集群 / .env / 网络
```

S2 工具目录

界面的 System 页从代码实时生成该名册：每个工具列出名字、完整描述、依赖，以及在本服务器上是否可用；读私有数据的工具另有标记。




图 9: System 页的工具名册（节选）

单细胞分析线

工具	作用
run_scanpy_qc	真实 scanpy 质控：逐细胞指标、细胞与基因过滤、归一化、log1p、高变基因选择
run_doublet_detection	Scrublet 双细胞打分，质控之后、聚类之前
run_integration	聚类前校正样本、供体与批次效应
run_clustering	PCA → 邻接图 → Leiden → UMAP；可用自举稳定性自动选分辨率
run_marker_annotation	按 marker panel 给每个簇指派细胞类型，支持谱系特异判别基因
run_de	差异表达（Wilcoxon）；标记模式与条件对比两种形态，支持按细胞类型分层
run_pseudobulk_de	聚合到每样本一条谱的条件间差异表达（pydeseq2 负二项 Wald）
run_depth_matched_de	分位数匹配 UMI 深度后重跑同一检验，按方向做 Spearman 相关
run_composition	细胞类型占比与条件间迁移
run_enrichment	离线 ORA（本地 .gmt），按组、按方向分别进行
run_gsea_prerank	预排序 GSEA，对每组完整排序列表，离线
scgpt_annotate	scGPT 参考式逐细胞注释（独立短时 GPU 批作业）

变异与表型线

工具	作用
annotate_variants	VCF 功能后果、受累基因、预测影响、ClinVar 临床意义；生产路径为 HPC3 离线 VEP 加 cache
map_phenotype_to_hpo	自由文本（任意语言）转经校验的 HPO 术语；本体拥有 ID，模型只选编号
run_lirical	表型驱动鉴别诊断，按校准后概率排序候选疾病
diagnose_disease	LIRICAL 概率与 PaperQA2 文献证据结合的裁决式鉴别诊断

文献线

工具	作用
<code>literature_search</code>	Europe PMC 关键词检索，取真实引用；检索式由被接受的发现构建
<code>deep_literature</code>	PaperQA2 深度检索增强生成，带引用的接地答案，全程在 HPC3

代码与文件

工具	作用
<code>run_code</code>	代码沙箱：读取本轮数据集与检查点、写出新产物；HPC3 Slurm 作业，默认上限 64 GB / 8 CPU / 1 小时
<code>list_dir · stat_path · find_files · read_text · disk_usage</code>	HPC3 文件系统只读查看
<code>run_shell · install_package · fetch_url</code>	HPC3 上受控的 shell、装包与取 URL

元工具

工具	作用
<code>inspect_dataset</code>	略读任意上传文件，返回结构化的格式、基因组版本、样本 ID 等
<code>read_tool_source</code>	读取自身分析工具的真实源码
<code>search_skills · read_skill_reference</code>	按关键词找原子技能，按渐进式披露读取其指引与代码
<code>make_schematic</code>	用文字描述结构，由确定性渲染器画出示意图
<code>finish</code>	结束本步并返回最终答案

S3 技术栈

第一层：Web 控制台

类别	内容
运行形态	主机 systemd 单元 <code>bioagent.service</code> ，绑定节点 IP :8800
对外	无 selector 的 k8s Service → Envoy Gateway
服务端	FastAPI + WebSocket (uvicorn)，Python ≥ 3.10
前端	原生 JS，无框架；Cytoscape (DAG 视图)、Mermaid (内联图)
账号	SQLAlchemy 2.0 + Alembic; bcrypt; itsdangerous 签名会话 cookie
数据库	生产 PostgreSQL 17 (psycopg 3)；开发与 CI 用 SQLite
传输	paramiko SSH + Duo；per-session 隧道；分块可续传上传；专用传输节点
邮件	UCI SER SMTP (STARTTLS + AUTH)

第二层：HPC3 计算

类别	内容
集群	UCI HPC3, Slurm
容器	Singularity 3.11.3
推理	vLLM, QuantTrio/Qwen3.6-35B-A3B-AWQ, OpenAI 兼容 /v1, 动态端口, per-user 隔离
推理参数	awq_marlin 量化； <code>--max-model-len 262144</code> ；显存利用率 0.92；工具解析 <code>qwen3_coder</code> ；思考解析 <code>qwen3</code>
GPU 请求	分区 <code>gpu</code> ，账号 <code>ruic20_lab_gpu</code> ， <code>--gres gpu:A100:1</code> ，8 CPU / 32 GB / 2 小时
分析	<code>scanpy · anndata · leidenalg · gseapy · pydeseq2 · matplotlib</code>
CPU 作业	分区 <code>standard</code> ；沙箱上限 64 GB / 8 CPU / 1 小时

类别	内容
变异	离线 VEP 加 cache; bcftools 1.21 / samtools / tabix / bedtools; pysam / cyvcf2; CADD、REVEL、AlphaMissense、OpenSpliceAI
表型	LIRICAL 2.4.1 (含 Exomiser hg19/hg38 数据)
文献	Europe PMC; PaperQA2 (本地模型与本地 embedding)
注释	scGPT (独立短时 GPU 批作业)
报告	pandoc → XeLaTeX (PDF) 与 DOCX; graphviz; 可选视觉模型复核
存储	/dfs3b/ruic20_lab; 共享临时目录按 3 天清理

依赖分组。pyproject.toml 将依赖切分为多个 extra 使核心与 CI 保持轻量：核心仅 h5py; gateway 为 paramiko、fastapi、uvicorn; auth 为 sqlalchemy、bcrypt、itsdangerous、psycopg、alembic; analysis 为 scanpy、pydeseq2、anndata、gseapy、matplotlib、leidenalg、pandas; literature 为 paper-qa[local]; langgraph 为独立 extra，惰性导入，未安装时默认规划器不受影响。系统级依赖为 pandoc、texlive-xetex、graphviz。

质量门。1,611 条离线测试; ruff 静态检查 (E4、E7、E9、F); GitHub Actions, main 分支四个必需检查。

S4 术语表

术语	含义
PI	Principal Investigator 角色，把问题拆成有序议程
Scientist	执行角色，逐步调用工具
Critic	评审角色，对每一步给出接受或修订与评分
议程	PI 产出的有序步骤列表
Plan mode	议程执行前的人工审阅暂停
run	一次完整运行，有唯一标识，产物落在独立目录
bundle	一次运行的可下载结果包
HarnessTool	工具的统一封装 (名字、描述、JSON schema、执行函数)
preset pipeline	预设流水线
skill	可重写的原子技能
eyeserver	承载 web 层的实验室服务器
HPC3	UCI 研究计算集群

S5 关键环境变量

代码中共有 207 个 BIOAGENT_* 变量，均同时接受 AISCIENTIST_* 前缀。

变量	默认	说明
BIOAGENT_HPC_HOST	hpc3.rcic.uci.edu	SSH 目标
BIOAGENT_HPC_TRANSFER_HOST	access-hpc3.rcic.uci.edu	文件传输主机
BIOAGENT_SLURM_PARTITION	gpu	GPU 分区
BIOAGENT_SLURM_ACCOUNT	ruic20_lab_gpu	计费账号
BIOAGENT_SLURM_GRES	gpu:A100:1	GPU 请求
BIOAGENT_GPU_CANDIDATES	空	多个 (分区, gres, 账号) 候选竞速
BIOAGENT_LAB_STORAGE	/dfs3b/ruic20_lab	研究数据根
BIOAGENT_HPC_SHARED_ROOT	.../software/AiScientist	容器、模型缓存、临时目录
BIOAGENT_VLLM_MODEL	QuantTrio/Qwen3.6-35B-A3B-AWQ	会话模型
BIOAGENT_VLLM_MAX_MODEL_LEN	262144	上下文窗口
BIOAGENT_VLLM_QUANTIZATION	awq_marlin	空为自动判断
BIOAGENT_LAB_LLM_BASE_URL 等	空	角色分流: PI/Critic/写作者指向另一模型
BIOAGENT_SECRET_KEY	无默认	签名会话 cookie, 必须强且唯一
BIOAGENT_DATABASE_URL	—	生产为 postgresql+psycopg://...
BIOAGENT_AGENT_MEMORY	0	专家演化记忆 (生产已开启)
BIOAGENT_PLANNER	linear	设为 dag 启用 DAG 规划器

变量	默认	说明
BIOAGENT_MAX_CONCURRENCY	1	独立分支并行度

HPC3 offload 开关: BIOAGENT_UPLOADS_ON_HPC、BIOAGENT_ANALYSIS_ON_HPC、BIOAGENT_REPORT_ON_HPC、BIOAGENT_RUN_CODE_ON_HPC、BIOAGENT_VARIANT_ON_HPC、BIOAGENT_PHENOTYPE_ON_HPC、BIOAGENT_PAPERQA_ON_HPC。

S6 路径约定

eyeserver (生产)

/data/BioAgent/app/	应用根
/data/BioAgent/app/.env	配置与密钥
/data/runs/	运行产物持久卷

HPC3

/dfs3b/ruic20_lab/	实验室存储根
/dfs3b/ruic20_lab/<UCInetID>/uploads/	用户上传
/dfs3b/ruic20_lab/software/AiScientist/	共享根
containers/	vllm.sif · analysis.sif · report.sif · vep.sif · scgpt.sif · vlreview.sif
hf/	HuggingFace 缓存 (共享 DFS, 非 \$HOME)
scgpt_model/	scGPT 权重
Temp/	per-run 过程文件, 3 天清理

S7 仓库结构

src/bioagent/

agents/	研究实验室、DAG 规划器、专家记忆、工具注册表、代码沙箱、溯源
gateway/	web 控制台: SSH+Duo、Slurm vLLM、账号、聊天历史、上传、报告组装
tools/	真实分析、文献、报告、scGPT 注释、视觉复核、示意图、变异、表型
lab/	研究实验室支撑
providers/	OpenAI 兼容 LLM 客户端
integrations/	DataBoundaryGuard 安全层
hpc/	Slurm 边界
core/	共享配置、品牌环境变量别名

frontend/console/ 浏览器 UI (按请求从磁盘提供)

deploy/ systemd 单元、k8s/Envoy、nginx、HPC3 容器定义、重部署工具

skills/ 15 个可重写的原子技能

preset_pipelines/ 7 条预设流水线

experiments/ 5 项测量与验证

docs/ 设计文档、ADR、规格、工作流

handoff/ 按工作线分目录的交接文档

tests/ 126 个文件, 25,981 行, 1,611 条用例

reports/ 日期化的进展报告与本手稿

S8 补充图例




图 10: 质控小提琴图: 逐细胞基因数、UMI 计数与线粒体比例的分布




图 11: UMAP: 稳定性选出的分辨率下得到的 20 个 Leiden 簇




图 12: 火山图 (Rod): log₂ 倍数变化对校正后 p 值




图 13: 通路富集条形图 (MG 上调方向): 离线 ORA 对本地基因集




图 14: 差异表达汇总：各细胞类型的显著基因数与上下调构成




图 15: 火山图 (MG): 本次运行中效应量最大的细胞类型，最大 abs log2FC 达 26.32

S9 资料出处

主张	出处
源码、测试、提交计数	仓库统计, 2026-09-05
体系结构、部署形态、依赖分组	README.md、pyproject.toml、deploy/README.md
角色循环、守卫、计划规则	src/bioagent/agents/、handoff/yijun/HANDOFF.md
工具描述	从 src/bioagent/**/*.py 的工具声明提取
界面截图	生产界面直接截取, 2026-09-05
样例运行 c135ae589d96	结果包 report/、figures/、tables/
九模型评测	experiments/plan_vs_exec_ab/ (2026-08-19, 两轮)
计划修订验证	experiments/plan_revision_ab/
深度匹配验证	experiments/depth_matched_validation/、result-2026-09-02.log (修复后)
会议证据分配	experiments/meeting_asymmetry/
协议格式 A/B	experiments/protocol_format/

主张	出处
KV cache 与上下文实测	ctxprobe 作业, 2026-08-02
节点与分区特性	handoff/yijun/HANDOFF.md, 2026-08-10
NVFP4 权重体积与服务栈	deploy/dsv4/ 及后续验证记录
MiniMax-M2.7 / M3 服务实测	4×96 GB 节点上的部署试验 (vLLM 0.22.1 / 0.27.1 / nightly), 2026-09 记录
Blackwell 设备显存	NVIDIA 产品页与厂商公布规格 (RTX PRO 6000 / 5000 / 4500: 96 / 48 / 32 GB GDDR7; B200: 180 GB HBM3e; B300: 288 GB HBM3e)
默认配置值	src/bioagent/gateway/settings.py